



TECNICATURA SUPERIOR
EN CIENCIAS DE DATOS E INTELIGENCIA ARTIFICIAL

TRABAJO FINAL DE CARRERA

MARINA GODOY

INTELIGENCIA ARTIFICIAL
PARA LA PREVENCIÓN DE PATOLOGÍAS EN LA CONSTRUCCIÓN

PROFESOR:
LIC.NATALIA RODRIGUEZ

Índice

Introducción.....	3
Capítulo 1 – Planteo del Problema.....	4
1.1 Problema de investigación.....	4
1.2 Justificación.....	4
1.3 Contexto actual del sector.....	5
1.4 Antecedentes.....	5
1.5 Soluciones existentes.....	6
Capítulo 2 – Hipótesis y Objetivos del Proyecto.....	7
2.1 Hipótesis principal.....	7
2.2 Supuestos.....	7
2.3 Objetivos Generales.....	7
2.4 Objetivos Específicos.....	7
Capítulo 3 – Marco Teórico.....	9
3.1 Fuentes primarias.....	9
3.2 Fuentes secundarias.....	11
3.3 Aportes de entrevistas.....	12
3.4 Variables relevantes.....	12
Capítulo 4 – Metodología.....	14
4.1 Recolección de datos.....	14
4.2 Selección de variables.....	14
4.3 Procesamiento.....	18
4.4 Modelos utilizados.....	18
Capítulo 5 – Desarrollo del Sistema y Resultados.....	19
5.1 Arquitectura técnica.....	19
5.2 Visualización del flujo.....	19
5.3 Aplicaciones prácticas.....	20
5.4 Prototipo.....	23
5.5 Presupuesto.....	27
Capítulo 6 – Conclusiones.....	29
6.1 Principales hallazgos.....	29
6.2 Impacto esperado.....	29
6.3 Limitaciones del estudio.....	30
6.4 Propuestas futuras.....	30
Bibliografía.....	31

Introducción

En la construcción de edificios nuevos, anticiparse a fallas podría marcar la diferencia entre una obra eficiente y un proyecto con sobrecostos y demoras. Fisuras, humedades o fallas en aislaciones pueden originarse incluso durante la ejecución si no se monitorean variables críticas desde el inicio. A partir de entrevistas con profesionales del sector y análisis técnico, surge una oportunidad: desarrollar un sistema predictivo inteligente que, mediante Inteligencia Artificial y Ciencia de Datos, permita detectar riesgos constructivos antes de que se manifiesten. Esta herramienta podría revolucionar la gestión de calidad en obra, optimizar decisiones técnicas y garantizar resultados más seguros, eficientes y duraderos.

Capítulo 1 – Planteo del Problema

1.1 Problema de investigación

La industria de la construcción enfrenta constantemente desafíos vinculados a la aparición de patologías constructivas, como fisuras, humedades, fallas estructurales y asentamientos. Estas problemáticas no solo derivan en elevados costos económicos y demoras, sino que también comprometen la seguridad de las personas y la durabilidad de las edificaciones.

A pesar de la implementación de controles de calidad tradicionales, muchas patologías siguen detectándose en etapas avanzadas del proyecto o incluso una vez finalizada la obra. Una de las principales falencias del sector radica en el escaso uso de herramientas predictivas basadas en datos que permitan anticiparse a dichas fallas.

1.2 Justificación

La incorporación de sistemas predictivos permite mejorar la calidad constructiva, reducir costos derivados de reparaciones, litigios y riesgos laborales, y aumentar la eficiencia y seguridad en las obras.

Actualmente existen sensores accesibles (acelerómetros, sensores de humedad, temperatura y deformación), plataformas de visualización y modelos de aprendizaje automático que pueden adaptarse al sector de la construcción. La aplicación de estos recursos ya ha demostrado ser viable en industrias como la automotriz, donde se utilizan para prevenir fallas técnicas.

Desde el punto de vista operativo, este tipo de sistema podría implementarse de manera gradual en la industria, comenzando con pruebas piloto en obras específicas y escalando progresivamente a múltiples proyectos.

1.3 Contexto actual del sector

La industria de la construcción en Argentina se encuentra en una etapa de transición hacia la digitalización. Si bien muchas empresas —especialmente pequeñas y medianas— aún utilizan métodos tradicionales de documentación y seguimiento (planillas en papel, inspecciones visuales, reportes físicos), comienzan a surgir iniciativas orientadas a modernizar estos procesos.

Un ejemplo destacado es el lanzamiento de la Biblioteca BIM Argentina, impulsada por la Cámara Argentina de la Construcción (CAMARCO) y la consultora Bimética. Este repositorio estandarizado y de libre acceso permite optimizar recursos, mejorar la especificación técnica en etapas tempranas y estructurar mejor la información dentro de modelos digitales (CAMARCO, 2025), posicionando a Argentina como pionera en Latinoamérica en este aspecto.

1.4 Antecedentes

Diversos estudios académicos han abordado las causas y consecuencias de las patologías constructivas, aunque la mayoría se enfoca en el diagnóstico postconstrucción, sin incorporar soluciones automatizadas ni predictivas.

Gea, Toledo y Nallim (s.f.) realizaron un estudio sobre un edificio patrimonial en Salta, empleando ensayos no destructivos y modelado numérico, pero sin inteligencia artificial.

Ramos, Rotondaro y Monk (2004) desarrollaron métodos de evaluación de patologías en construcciones de tierra del noroeste argentino mediante técnicas de diagnóstico cualitativo y cuantitativo.

Torzoni et al. (2023) propusieron un marco de gemelo digital para estructuras de ingeniería civil, integrando modelos probabilísticos y aprendizaje profundo para monitoreo predictivo en puentes.

A nivel nacional, instituciones como el CONICET y el Instituto Eduardo Torroja han iniciado proyectos con sensores e IA, aunque aún no existe una solución integral para prevenir patologías desde etapas tempranas en obras civiles comunes.

1.5 Soluciones existentes

Las soluciones aplicadas hasta el momento pueden dividirse en tres grandes categorías:

Métodos tradicionales: Incluyen inspecciones visuales, ensayos de laboratorio y revisiones periódicas. Si bien aportan información valiosa, son costosos, demandan tiempo y no siempre detectan problemas ocultos.

Sistemas de monitoreo estructural: Utilizan sensores para medir vibraciones, temperatura o humedad, pero suelen limitarse a monitoreo pasivo y se aplican solo en infraestructuras críticas.

Plataformas BIM con algoritmos de IA: Proyectos emergentes que aplican inteligencia artificial en fases de planificación, sin un enfoque específico en patologías ni en la etapa de ejecución.

Como conclusión, ninguna de estas soluciones aborda de manera integral la predicción temprana de fallas a partir de la combinación y análisis de múltiples fuentes de datos durante la construcción.

Capítulo 2 – Hipótesis y Objetivos del Proyecto

2.1 Hipótesis principal

La implementación de un sistema predictivo basado en inteligencia artificial y análisis de datos durante la etapa de construcción permite anticipar y reducir significativamente la aparición de patologías estructurales o constructivas en edificios.

2.2 Supuestos

Las empresas constructoras podrían contar con registros estructurados y sensores en obra.

Las variables que influyen en la aparición de patologías (clima, materiales, ejecución) pueden ser medidas y modeladas.

Los modelos de aprendizaje automático generalizan comportamientos anómalos si se entrenan con datos adecuados.

2.3 Objetivos Generales

Desarrollar un sistema predictivo basado en técnicas de Ciencia de Datos e Inteligencia Artificial que permita identificar y prevenir las patologías constructivas más frecuentes durante la ejecución de obras edilicias, para mejorar la calidad constructiva, disminuir los costos asociados a reparaciones y aumentar la seguridad estructural de la obra

2.4 Objetivos Específicos

Identificar y recolectar variables críticas asociadas a la aparición de patologías constructivas, considerando factores como materiales utilizados, condiciones climáticas y procesos de ejecución de obra.

Diseñar e implementar una arquitectura de datos que integre y gestione eficientemente información proveniente de múltiples fuentes: documentación técnica, sensores en obra e informes de inspección.

Desarrollar e implementar modelos de aprendizaje automático que permitan detectar patrones de riesgo asociados a patologías constructivas, priorizando su aplicación en tiempo real durante la etapa de ejecución edilicia.

Diseñar una interfaz de usuario interactiva que facilite la interpretación de los resultados del sistema, la visualización de alertas y la recomendación de acciones correctivas de forma clara, accesible e intuitiva para los usuarios finales.

Capítulo 3 – Marco Teórico

3.1 Fuentes primarias

Las principales fuentes primarias fueron las entrevistas y charlas realizadas con profesionales del ámbito de la arquitectura y la construcción, lo que permitió obtener información de primera mano sobre las problemáticas reales que enfrentan en obra. Se llevaron a cabo conversaciones informales y consultas técnicas con tres arquitectos con experiencia directa en patologías edilicias. De este conjunto de aportes, se destaca especialmente la entrevista mantenida con el arquitecto Gaston Altizio, especialista en patologías constructivas, quien brindó una visión detallada sobre las zonas críticas, causas frecuentes de deterioro y recomendaciones específicas para alimentar modelos predictivos.

Dicha interacción fue clave para orientar el diseño del dataset y ajustar la lógica de detección del modelo. Además, se mantuvo un intercambio por correo electrónico con este profesional, a quien se le presentaron los avances del proyecto y se le consultó sobre posibles mejoras a incorporar en la fase final de documentación y prueba.

Investigación de patologías

Las patologías constructivas son defectos o fallas que

aparecen en una edificación, afectando su funcionalidad, durabilidad y/o seguridad. Pueden manifestarse durante la obra, al finalizar, o a lo largo de su vida útil. En proyectos de arquitectura e ingeniería, la prevención temprana de estas patologías es clave para garantizar la calidad constructiva, evitar costos asociados a reparaciones, y resguardar la integridad de los usuarios.

En el marco de este trabajo se investigaron las principales patologías que afectan a las edificaciones en etapa de construcción, con el fin de alimentar un sistema de visión artificial basado en YOLOv8, que permita detectar signos visibles (como fisuras) de forma

automática. La investigación combinó fuentes bibliográficas y documentos con entrevistas a profesionales del sector.

Clasificación General de Patologías

De la investigación realizada surgió la siguiente clasificación de las patologías constructivas, que fueron clasificadas en base a su tipo, causa principal, manifestación visible y etapa probable de aparición.

Tipo de Patología	Causa Frecuente	Manifestación	Zona Crítica	Etapa de Aparición
Fisuras estructurales	Asentamientos, errores de cálculo, mal apuntalado	Grietas lineales o ramificadas	Muros portantes, losas, vigas	Durante o post ejecución
Fisuras por retracción	Secado rápido del revoque u hormigón	Grietas superficiales	Revoques, tabiques	A los pocos días
Humedad ascendente	Capilaridad desde el terreno	Decoloración, salitre, desprendimiento	Planta baja, muros en contacto con suelo	Durante o meses después
Humedad descendente	Filtraciones de cubierta, lluvia, rotura de caños	Manchas, pintura inflada	Techos, encuentros con muros	Pos lluvia o uso del edificio
Humedad por condensación	Diferencias térmicas internas	Hongos, manchas grises	Baños, cocinas, cerramientos	Estacional o uso intensivo

3.2 Fuentes secundarias

Las fuentes secundarias consultadas se centraron en bibliografía técnica y académica sobre patologías en la construcción, incluyendo estudios de casos, informes de organismos oficiales y literatura especializada en fisuras, humedades y fallas estructurales. Entre ellas se destacan los trabajos de Gea, Toledo y Nallim, el estudio de Ramos, Rotondaro y Monk sobre construcciones de tierra, y el modelo propuesto por Torzoni et al. (2023) en el ámbito internacional, enfocado en gemelos digitales y aprendizaje profundo para mantenimiento predictivo.

Estas fuentes aportan un panorama claro sobre la detección de patologías, sirviendo como base para justificar la aplicación de herramientas basadas en visión por computadora, sensores IoT y aprendizaje automático, como las que se desarrollaron en este proyecto.

Asimismo, se revisaron documentos de referencia nacional como los informes del CONICET, publicaciones de la Cámara Argentina de la Construcción (CAMARCO) y los contenidos de la Biblioteca BIM Argentina, que sirvieron para contextualizar el grado de

digitalización del sector y las oportunidades reales de implementación de soluciones automatizadas.

Como se mencionó anteriormente, las entrevistas fueron de gran ayuda con los diferentes referentes del área.

3.3 Aportes de entrevistas

En la entrevista realizada, el Arq. Gastón Altizio destacó varias zonas críticas que deben ser monitoreadas desde la etapa de ejecución para anticipar fallas:

- Encuentros entre materiales distintos (ej. hormigón y mampostería).
- Juntas mal ejecutadas en revoques.
- Cubiertas planas y encuentros con desagües.
- Bases de muros sin correcta barrera hidrófuga.
- Columnas expuestas a filtraciones o mal recubrimiento.
- Además, enfatizó que los signos visuales tempranos más comunes y detectables son:
 - Grietas lineales o en forma de telaraña.
 - Desprendimientos o burbujas en revoque.
 - Cambios de color por humedad.
 - Presencia de eflorescencias (sales blancas).

3.4 Variables relevantes

Para desarrollar un sistema de IA capaz de predecir o detectar estas patologías, se definieron las siguientes variables técnicas:

- Tipo de muro (portante, tabique).
- Materiales utilizados (ladrillo, H°A°, revoque).
- Estado del terreno y napa freática.
- Condiciones meteorológicas durante la obra.
- Datos de sensores: humedad, temperatura, vibración.
- Registro fotográfico (cámaras).

La investigación permitió identificar un conjunto de patologías prioritarias para ser incluidas en un sistema inteligente de detección. A través del cruce entre documentación técnica y entrevistas a profesionales, se definieron zonas críticas, variables de riesgo y signos visibles que permiten modelar un sistema de alerta y detección con visión artificial.

Si bien existen limitaciones por la variabilidad de los casos y el entorno no controlado de obra, se comprobó que la visión por computadora puede ser una herramienta válida y escalable para contribuir a la prevención de patologías desde etapas tempranas, reduciendo riesgos estructurales, costos de reparación y tiempos de obra.

Capítulo 4 – Metodología

4.1 Recolección de datos

El primer paso para desarrollar un modelo de predicción confiable es la creación de un conjunto de datos representativo. Aquí describo el proceso seguido para construir, depurar y analizar el dataset utilizado. Incluye las variables seleccionadas, las fuentes consultadas, las técnicas de limpieza aplicadas y los principales hallazgos derivados de la exploración de datos.

En el desarrollo del presente trabajo, se recurrió a un enfoque combinado que integra tanto fuentes primarias como fuentes secundarias, con el objetivo de construir un marco teórico robusto y contextualizado sobre las patologías constructivas y su prevención mediante inteligencia artificial.

4.2 Selección de variables

A partir de la revisión bibliográfica (como la Guía de Buenas Prácticas) y entrevistas con profesionales del sector, se definió un conjunto de variables con potencial predictivo para la aparición de fisuras en obras nuevas.

Categoría	Atributo	Descripción / Valor esperado
Tipología de Humedades	tipo_humedad	Tipo de humedad: ascendente, descendente, condensación, eflorescencia, etc.
Mampostería y Muros	espesor_muro	Espesor del muro en cm
	tipo_ladrillo	Ladrillo común, hueco, portante, cerámico, etc.
	tipo_mortero	Cal, cemento-cal, mezcla industrializada, etc.
	presencia_capa aisladora	Sí / No
	cámara_de_aire_ventilada	Sí / No
	presencia_rejillas_ventilación	Sí / No
Entorno y Suelos	profundidad_napa	En cm o m
	movimiento_suelos_detectado	Sí / No / Probable
	estado_cimientos	Bueno / Regular / Malo
Cubiertas y Pendientes	tipo_cubierta	Chapa, losa, teja, etc.
	estado_membrana	Intacta / Agrietada / Ausente
	estado_zingueria	Bueno / Obstruida / Faltante
	verificación_desagües	Realizada / No realizada

Categoría	Atributo	Descripción / Valor esperado
	presencia_cupertinas_babetas	Sí / No
Revestimientos	tipo_pintura	Latex, impermeabilizante, sintética, etc.
	presencia_ornatos/historicidad	Sí / No (valor patrimonial)
	estado_revoque	Bueno / Craquelado / Caído
Fisuras y Grietas	tipo_falla	Vertical, horizontal, diagonal, estructural, superficial
	ancho_fisura	En mm
	testigo_colocado	Sí / No
	estado_fisura	Activa / Estabilizada / Reabierta
	profundidad	Superficial / Intermedia / Profunda

Estas variables fueron organizadas en un formato tabular (CSV/Excel), en un total de aproximadamente 50 registros

Variable	Tipo	Descripción
Tipo de muro	Categórica	Ladrillo hueco, portante, tradicional, muro de carga, etc.
Tipo de mortero	Categórica	Cementicio, cal, mixto, premezclado, etc.
Espesor de muro	Numérica	Medido en centímetros.
Presencia de aislación	Binaria	Si/No, capa hidrófuga u otra protección.
Nivel freático	Categórica	Bajo, medio, alto, no conocido.
Tipo de suelo	Categórica	Suelo arcilloso, granular, mixto, rellenado.
Estado de cimientos	Categórica	Adecuado, insuficiente, con refuerzos, no evaluado.

Presencia de humedad detectada	Binaria	Si/No. Humedad ascendente, descendente o por filtración.
Fase de obra	Categórica	Fundación, estructura, cerramientos, instalaciones, terminaciones.
Condición climática promedio	Categórica	Seco, húmedo, lluvioso, combinaciones según ubicación.
Presencia de fisuras (target)	Binaria	Variable objetivo: 1 = presencia de fisura; 0 = no detectada.

4.3 Procesamiento

- Modelos de visión por computadora (CNN) para detectar visualmente fisuras, filtraciones, desprendimientos incipientes.
- Algoritmos supervisados (Random Forest, SVM) para clasificar zonas según riesgo de falla.
- Detección de incompatibilidades entre materiales, técnicas y condiciones ambientales.

4.4 Modelos utilizados

- Modelos de regresión y series temporales para anticipar aparición de patologías.
- Modelos secuenciales para prever condiciones peligrosas antes de que ocurran.
- Predicción de fallas según combinación de variables (clima + técnica + material).

Capítulo 5 – Desarrollo del Sistema y Resultados

5.1 Arquitectura técnica

- Dispositivos: cámaras , sensores de humedad, temperatura, vibración, etc.
- Servidor / Plataforma IA: recibe los datos, ejecuta los modelos de detección y predicción (incluyendo YOLOv8 para fisuras y visión por computadora).
- Base de Datos: almacena imágenes, mediciones sensóricas, resultados de predicción, alertas generadas y usuarios.
- Aplicación: muestra resultados, mapas de riesgo, alertas, reportes, y permite tomar decisiones.

5.2 Visualización del flujo

- Captura de datos : Cámaras y sensores IoT capturan imágenes y mediciones en forma periódica o en tiempo real durante la obra.
- Preprocesamiento :Limpieza y normalización de datos. Las imágenes se escalan y ajustan al formato compatible con YOLOv8; los datos de sensores se validan para reducir ruido.
- Análisis IA
Aplicación del modelo YOLOv8 para detección automática de fisuras en imágenes, y modelos supervisados (como Random Forest o SVM) para clasificación de zonas según riesgo en base a variables numéricas/sensóricas.
- Generación de alertas y reportes
Si se detectan patologías o zonas críticas, se activa una alerta automática que se registra en el sistema y se comunica al usuario
- Visualización
El usuario accede a un panel de control con visualización de alertas, mapa de riesgos, historial de condiciones y sugerencias técnicas.

5.3 Aplicaciones prácticas

```

!pip install ultralytics==8.3.158
import os
import subprocess
import logging
from pathlib import Path
from ultralytics import YOLO
import zipfile

# Configuración de logging
logging.basicConfig(
    level=logging.INFO,
    format='%(asctime)s - %(levelname)s - %(message)s',
    handlers=[logging.StreamHandler()]
)
logger = logging.getLogger(__name__)

def clone_yolov8_if_needed(repo_path: Path) -> None:
    """Clona el repositorio YOLOv8 si no existe."""
    if not repo_path.exists():
        logger.info(f"Clonando repositorio YOLOv8 en {repo_path}...")
        subprocess.run(
            ["git", "clone", "https://github.com/ultralytics/ultralytics.git", str(repo_path)],
            check=True
        )
        logger.info("Repositorio clonado exitosamente")

def unzip_dataset(zip_path: Path, extract_dir: Path) -> None:
    """Descomprime el dataset en el directorio especificado."""
    logger.info(f"Descomprimiendo dataset en {extract_dir}...")
    with zipfile.ZipFile(zip_path, 'r') as zip_ref:
        zip_ref.extractall(extract_dir)
    logger.info("Dataset descomprimido exitosamente")

def create_data_yaml(yaml_path: Path, data_dir: Path) -> None:
    """Crea el archivo data.yaml requerido por YOLOv8."""
    content = f"""train: {data_dir}/train/images
val: {data_dir}/valid/images
test: {data_dir}/test/images

nc: 1
names: ['grieta']
"""
    yaml_path.parent.mkdir(parents=True, exist_ok=True)
    with open(yaml_path, 'w') as f:
        f.write(content)
    logger.info(f"Archivo data.yaml creado en {yaml_path}")

def train_yolov8(repo_path: Path, yaml_path: Path, epochs: int, batch_size: int, img_size: int, model_size: str, run_name: str) -> None:
    """Entrena el modelo YOLOv8 con los parámetros dados."""
    logger.info("Iniciando entrenamiento de YOLOv8...")

    # Carga el modelo
    model = YOLO(model_size)

```

```
# Muestra los resultados
for result in results:
    result.show()

logger.info("Detección completada")

def display_grietas_image() -> None:
    """Muestra la imagen final de detección."""
    from PIL import Image
    import matplotlib.pyplot as plt

    logger.info("Mostrando imagen final de detección...")
    sample_detection = Path("runs/detect/exp/Grieta_0047_jpg.rf.e4ff9cf032992c654491ac3a41d93648.jpg")

    if sample_detection.exists():
        img = Image.open(sample_detection)
        plt.figure(figsize=(10, 10))
        plt.imshow(img)
        plt.axis('off')
        plt.title("Resultados de Detección de Grietas")
        plt.show()
    else:
        logger.warning("Imagen de detección no encontrada")

def main() -> None:
    """Función principal para ejecutar el pipeline de entrenamiento y detección de YOLOv8."""
    logger.info("Pipeline de Entrenamiento de YOLOv8 Iniciado")

    base_path = Path.cwd()
    repo_path = base_path / "yolov8"
    dataset_zip = base_path / ".." / "Grietas-.v3i.yolov8pytorch.zip"
    extract_dir = base_path / ".." / "grietas_dataset"
    yaml_path = extract_dir / "data.yaml"
    run_name = "grietas_yolo8"
    model_size = "yolov8s.pt" # Puedes cambiar a yolov8m.pt, yolov8l.pt, etc.
    epochs = 100
    batch_size = 16
    img_size = 640
```

```
try:
    # 1. Clonar el repositorio YOLOv8
    clone_yolov8_if_needed(repo_path)

    # 2. Cambiar el directorio de trabajo a yolov8
    os.chdir(repo_path)
    logger.info(f"Cambiando el directorio de trabajo a: {os.getcwd()}")

    # 3. Descomprimir el dataset
    unzip_dataset(dataset_zip, extract_dir)

    # 4. Crear el archivo data.yaml
    create_data_yaml(yaml_path, extract_dir)

    # 5. Entrenar YOLOv8
    train_yolov8(repo_path, yaml_path, epochs, batch_size, img_size, model_size, run_name)

    # 6. Mostrar resultados del entrenamiento
    display_training_results(repo_path / "runs" / "train" / run_name)

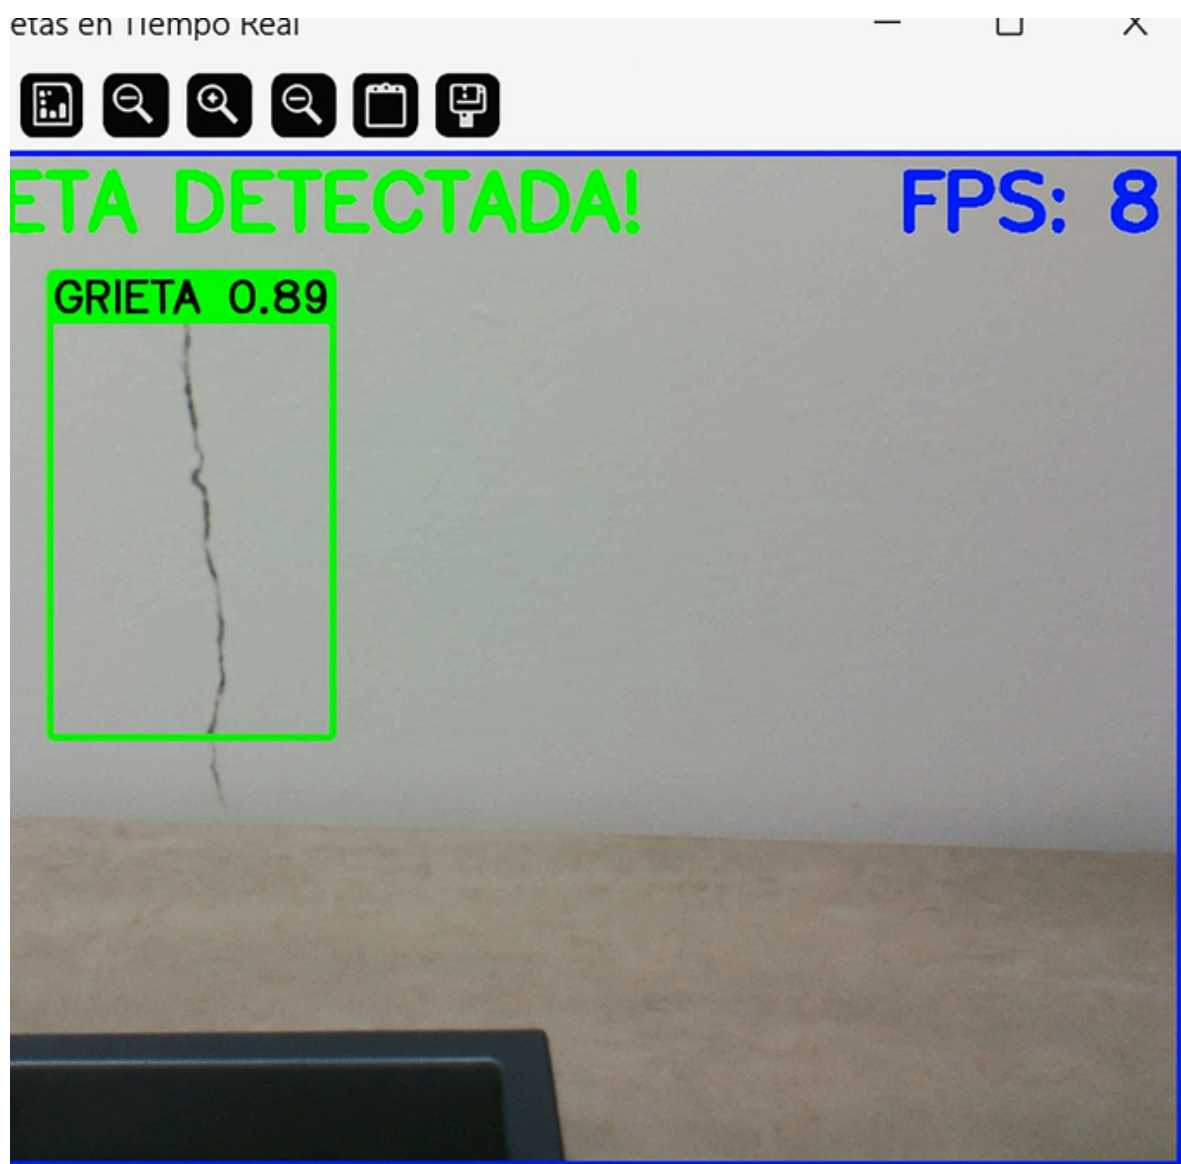
    # 7. Ejecutar detección en una imagen de muestra
    logger.info("Ejecutando detección en la imagen de muestra...")
    sample_img_path = extract_dir / "test" / "images" / "Grieta_0047_jpg.rf.e4ff9cf032992c654491ac3a41d93648.jpg"
    model_weights_path = repo_path / "runs" / "train" / run_name / "weights" / "best.pt"
    detect_on_sample_image(model_weights_path, sample_img_path)

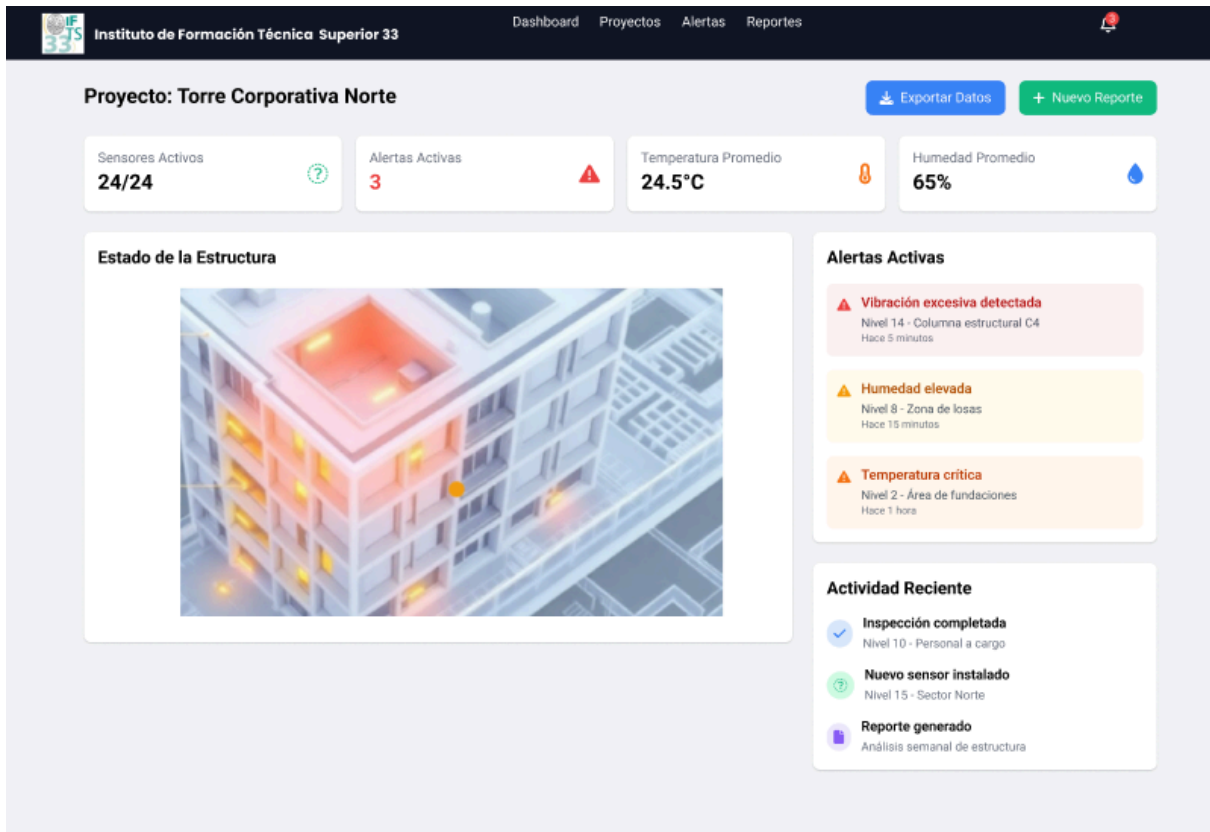
except subprocess.CalledProcessError as e:
    logger.error(f"Error en el proceso: {e}. Por favor, verifica los errores anteriores.")
except FileNotFoundError as e:
    logger.error(e)
except Exception as e:
    logger.error(f"Ocurrió un error inesperado: {e}")
else:
    # Mostrar la imagen final de detección
    display_grietas_image()

if __name__ == "__main__":
    main()
```

5.4 Prototipo


Cámara en tiempo real , plataforma y app





Marina Godoy Trabajo Integrador ▾





Proyecto Final Marina Godoy



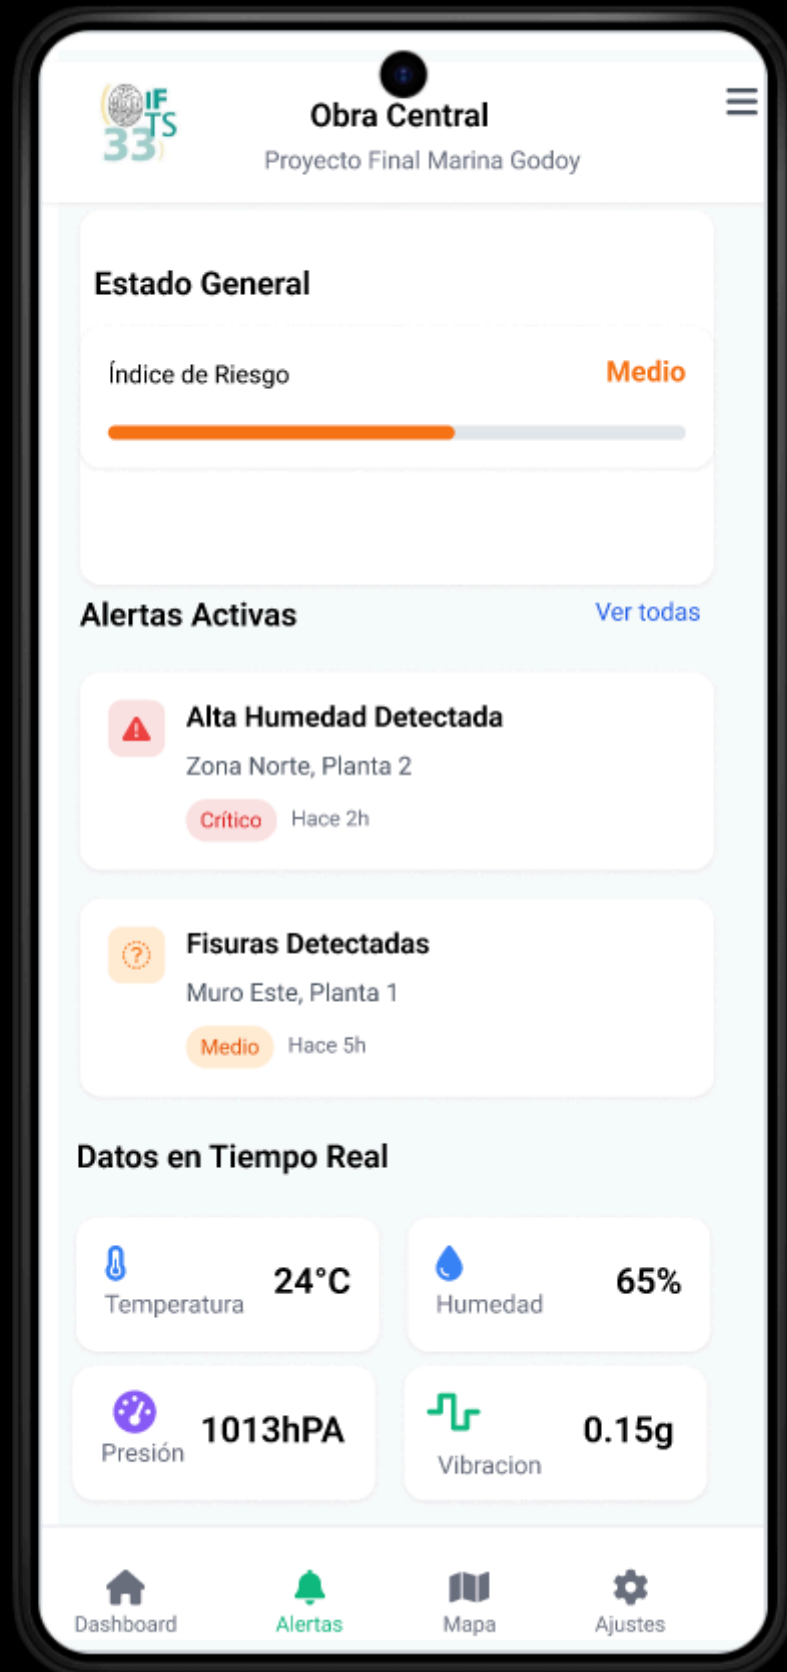
Email

Contraseña

Iniciar Sesión

 Inicio  Alertas  Mapa  Ajustes

Marina Godoy Trabajo Integrador ▾



5.5 Presupuesto

Elemento básicos

Categoría	Dispositivo	Cantidad	Precio Unitario (AR\$)	Subtotal (AR\$)	Fuente
Cámaras	Logitech C920 HD Pro (nuevo)	5	\$42.000	\$210.000	Amazon vía Logitech
Sensores	DHT22 AM2302 (humedad + temperatura)	6	\$13.000	\$78.000	Itytarg
	MPU6050 (acelerómetro)	6	\$10.000	\$60.000	MercadoLibre oficial (precio referencial)
Procesadores	ESP32-C3 DevKit (para conectar sensores)	5	\$18.000	\$90.000	MercadoLibre - Starware
Almacenamiento	Tarjeta microSD SanDisk 64GB	5	\$8.000	\$40.000	SanDisk en MercadoLibre o Amazon
Energía	Power Bank Xiaomi 10.000mAh	5	\$25.000	\$125.000	Xiaomi Store AR o ML
Accesorios	Cables, placas base, conectores	—	—	\$25.000	Estimación general

Elementos adicionales

Categoría	Elemento	Función	Precio Estimado (AR\$)	Observaciones
Protección	Caja estanca IP65 / IP67	Proteger sensores y placas del clima, polvo y humedad	\$20.000 (x5) = \$100.000	Una por estación de sensores
	Dome protector para cámaras	Protección antivandálica y climática	\$18.000 (x5) = \$90.000	Una por cámara
Soporte físico	Trípodes / anclajes para cámaras	Instalación estable en obra o fachada	\$12.000 (x5) = \$60.000	Alternativas: trípodes, caños, abrazaderas
Conectividad	Router Wi-Fi 4G con chip	Transmisión remota de datos (si no hay red fija)	\$55.000	Con chip de datos móviles
	Plan de datos IoT (chip prepago o abono)	Transmisión mensual	\$5.000/mes	Estimado por línea de datos
Autonomía	Panel solar + batería	Energía autónoma para estaciones en exteriores	\$60.000 (x3) = \$180.000	Alternativas desde kits Arduino hasta solares de 12V
Calibración / Validación	Medidor portátil de humedad	Comparación y validación contra sensores IoT	\$45.000	Ej.: Medidor Testo, Fluke o genérico

Total general (equipamiento base + prueba de campo):
AR\$ 628.000 (base) + AR\$ 630.000 (campo) = AR\$ 1.258.000

Capítulo 6 – Conclusiones

6.1 Principales hallazgos

A lo largo del desarrollo de este trabajo pude comprobar que la aplicación de técnicas de inteligencia artificial, visión por computadora y sensores IoT permite anticipar la aparición de patologías constructivas en obras nuevas. La hipótesis inicial se vio reforzada por los resultados obtenidos tanto en la construcción del dataset como en la implementación de modelos de detección temprana de fisuras y humedades.

Durante la investigación identifiqué que muchas de estas patologías responden a patrones previsibles, ya sea por causas materiales, ambientales o constructivas, y que esos patrones pueden ser representados mediante variables técnicas. La combinación entre análisis bibliográfico y entrevistas con profesionales del sector fue fundamental para delimitar zonas críticas, definir atributos relevantes y validar el enfoque del sistema.

6.2 Impacto esperado

Considero que el desarrollo de este tipo de herramientas puede generar un cambio significativo en la forma de gestionar la calidad durante la ejecución de obras. Entre los principales beneficios que se esperan, destacó:

- La reducción de costos relacionados con reparaciones o litigios derivados de fallas no detectadas a tiempo.
- Un mayor nivel de seguridad estructural, al prevenir situaciones de riesgo desde etapas tempranas.
- La posibilidad de contar con trazabilidad técnica continua, integrando sensores, imágenes y reportes en un mismo sistema.
- La mejora en la toma de decisiones técnicas, basadas en datos objetivos y no únicamente en experiencia empírica.

Este sistema también puede contribuir a profesionalizar el proceso constructivo, fomentando una cultura preventiva dentro del sector.

6.3 Limitaciones del estudio

Soy consciente de que el trabajo presenta ciertas limitaciones. Una de ellas fue la cantidad de registros disponibles para entrenar los modelos, lo cual restringe el alcance de las predicciones. Otra limitación importante es que no todas las obras cuentan con sensores instalados o documentación digitalizada, lo cual condiciona la escalabilidad del sistema.

Además, la detección mediante visión por computadora requiere condiciones ambientales óptimas (iluminación, visibilidad, estabilidad de cámara) que no siempre se pueden garantizar en obra. También existe una variabilidad propia de cada proyecto (materiales, técnicas, equipos humanos) que podría afectar la generalización del modelo.

6.4 Propuestas futuras

A partir de esta experiencia, propongo continuar con las siguientes líneas de trabajo:

- Ampliar el volumen y diversidad del dataset, incorporando registros de diferentes zonas geográficas, tipos de obra y condiciones climáticas.
Desarrollar estaciones sensóricas autónomas, con energía solar y conectividad remota, que puedan instalarse en cualquier etapa de la obra.
- Validar el funcionamiento del sistema en situaciones reales, realizando pruebas piloto en campo junto a equipos técnicos.
- Incluir métricas de rendimiento específicas (precisión, recall, F1-score) para evaluar la eficacia de cada modelo aplicado.
- Estudiar la posibilidad de integrar esta solución con plataformas BIM y cronogramas de obra para una supervisión técnica continua y coordinada.

Bibliografía

Referencias bibliográficas

- Gea, S. B., Toledo, M. W. E., & Nallim, L. G. (s.f.). Evaluación y diagnóstico de patologías de un edificio patrimonial del Ministerio de Salud de la Nación (Argentina). Universidad Nacional de Salta.
- Gobierno de la Ciudad Autónoma de Buenos Aires. (s.f.). Permisos. <https://buenosaires.gob.ar/permisos>
- Instituto Eduardo Torroja de Ciencias de la Construcción. (s.f.). Proyectos de investigación en monitoreo estructural y durabilidad. Consejo Superior de Investigaciones Científicas (CSIC). Recuperado de <https://www.ietcc.csic.es/>
- Ramos, A. R., Rotondaro, R., & Monk, F. (2004). Diseño y aplicación de métodos para evaluar patologías constructivas en el hábitat rural. Arquitectura de tierra en el noroeste argentino. Revista INVI, 19(51), 108–127. <https://doi.org/10.5354/0718-8358.2004.62280>
- Torzoni, M., Tezzele, M., Mariani, S., Manzoni, A., & Willcox, K. E. (2023). A digital twin framework for civil engineering structures. arXiv preprint. <https://arxiv.org/abs/2308.01445>
- Cámara Argentina de la Construcción (CAMARCO). (2025, mayo 29). Digitalización de la construcción: Biblioteca BIM Argentina. <https://www.camarco.org.ar/2025/05/29/digitalizacion-de-la-construccion-biblioteca-bim-argentina/>
- Muñoz Hidalgo, M. (2000). Manual de Patología de la Edificación: Detección, Diagnóstico y Soluciones. Editorial Munillalería.
- Eichler, F. (1973). Patología de la construcción: detalles constructivos. Editorial Blume.

Fuentes de presupuesto y equipamiento

- Logitech. (2025, junio). Logitech cámara web C920 HD Pro. Amazon. <https://www.amazon.com/dp/B006A2Q81M>
- Itytarg. (2025). DHT22 AM2302 sensor humedad temperatura digital. Itytarg Tienda. <https://www.itytarg.com.ar/productos/dht22-am2302-sensor-humedad-temperatura-digital/>
- Starware. (2025). ESP32-C3 DevKitC-02 WROOM. MercadoLibre. <https://www.mercadolibre.com.ar/>
- SanDisk. (2025). Tarjeta microSD SanDisk 64GB. Amazon. <https://www.amazon.com/dp/B07FCMBLV6>
- Xiaomi. (2025). Power Bank 10.000mAh – Modelo V3. Xiaomi Store Argentina. <https://www.mercadolibre.com.ar/>